

Abordagem Baseada em Conteúdo para Recomendação Literária: Uma Arquitetura com Grafos e Huffman

Daniel Vieira Holanda
Engenharia de Computação
CEFET - MG
Divinópolis, Brasil
dannielvh7@gmail.com

Luíza Magalhães Miranda
Engenharia de Computação
CEFET - MG
Divinópolis, Brasil
magalhaesmirandalu@gmail.com

Abstract—Os sistemas de recomendação de livros atuais baseiam-se quase exclusivamente em métricas de popularidade, negligenciando a compatibilidade temática. Para fugir dessa limitação, propomos um sistema baseado em conteúdo, focado na afinidade entre subgêneros literários. A modificação principal modela o domínio literário como um grafo, onde cada vértice é representado por um subgênero e possui uma estrutura dupla de árvores de Huffman: uma para popularidade e outra para o conteúdo das sinopses. A similaridade entre os subgêneros é calculada por uma função que utiliza as métricas de popularidade e conteúdo, criando arestas apenas para pares com similaridade acima do limiar. O grafo então forma clusters e revela conexões, mostrando que o sistema facilita a descoberta ao recomendar livros de subgêneros próximos. Os resultados comprovam a abordagem como uma alternativa para os modelos baseados em popularidade, priorizando a exploração por temas.

Index Terms—Sistemas de Recomendação, Recomendação de Livros, Grafo, Árvore de Huffman, Busca em Largura, Compatibilidade Temática.

I. INTRODUÇÃO

O mercado editorial contemporâneo expande-se exponencialmente, tanto no volume de títulos publicados quanto no crescimento de nichos temáticos. Esse fenômeno é extremamente positivo quando se discute sobre a democratização da literatura, porém, gera também um efeito colateral muito crítico para o leitor: uma sobrecarga de informação. Atualmente existe um catálogo virtual ilimitado, com tantos títulos a disposição de maneira tão fácil, o processo de seleção se torna complexo e demasiadamente desgastante, fazendo com que os usuários recorram aos sistemas de recomendação. No entanto, os sistemas predominantes nas grandes livrarias e nas plataformas digitais apoiam-se quase exclusivamente em métricas baseadas em popularidade, como listas de best-sellers e de compras em massa. Observa-se então que essa abordagem tende a criar um ciclo onde as sugestões vão se tornando mais uniformizadas, priorizando a visibilidade massiva de livros mais populares em detrimento da afinidade temática entre eles. Essa dinâmica que é tão amplamente explorada e discutida na literatura da área tende a negligenciar inúmeros títulos do catálogo editorial, e ainda desconsidera a singularidade dos interesses de cada usuário, o que acaba

resultando em recomendações genéricas que frequentemente falham em considerar a compatibilidade entre o livro e as preferências do leitor.

Diante dessa lacuna, o presente artigo tem como objetivo principal propor o desenvolvimento de um sistema de recomendação literária que tem como prioridade o conteúdo e os temas das obras como critério central, além da classificação de leitores reais. Para tanto, descreve-se a implementação de um modelo de solução que, a partir dos subgêneros declarados pelo usuário como de seu interesse, busca volumes que estejam relacionados por meio de uma estrutura de dados em grafo. Este grafo, que mapeia essas relações de proximidades entre os subgêneros, é percorrido de maneira estratégica por um algoritmo de Busca em Largura (BFS), enquanto a estrutura de cada vértice é modelada por uma Árvore de Huffman, que utiliza uma média bayesiana para ponderar e priorizar as obras mais relevantes estatisticamente. O trabalho argumenta que, aos deslocar o foco da popularidade para uma conexão temática entre os livros, é possível retornar sugestões mais personalizadas e relevantes, o que contribui para uma experiência mais alinhada aos interesses individuais de cada usuário.

II. REFERENCIAL TEÓRICO

Esta seção fundamenta o sistema proposto de recomendação, abordando desde discussões sobre o fenômeno da sobrecarga de informação até as estruturas de dados e algoritmos que formam a base técnica da solução implementada, passando pelas limitações dos sistemas de recomendação tradicionais e pelas alternativas baseadas em conteúdo.

A revolução digital transformou de maneira radical o mundo editorial e literário, atualmente, com tantas plataformas de autopublicação, livrarias online e o próprio e-book, tudo isso resultou em uma explosão no número de títulos disponíveis. Robert Armstrong, em seu artigo da revista Wired em outubro de 2004 [1], descreveu sobre um modelo de negócios onde a venda de pequenos volumes de muitos itens de nicho pode ser tão lucrativa quanto a venda de grandes volumes de poucos itens populares. Esse é o conceito de “The Long Tail” (A Cauda Longa), onde nichos de mercado que antes eram

inviáveis se tornem economicamente relevantes, e no contexto editorial essa “cauda longa” representa a vasta coleção de livros com baixo volume de vendas individual, mas que, coletivamente, podem representar uma parcela significativa desse mercado. No entanto, Anderson aponta que o grande desafio em mercados de long tail não é a oferta, mas como conectar o produto de um nicho ao consumidor que se interesse por aquilo.

É justamente nesse ponto que surge então o fenômeno da Sobrecarga de Informação (Information Overload). Definido como a dificuldade em se tomar uma decisão ou processar informações quando se tem uma quantidade excessiva de dados [2], o information overload coloca o leitor em um estado de paralisia pela escolha. Assim, a curadoria deixa de ser apenas um luxo e torna-se uma necessidade funcional, sendo delegada em grande parte para os algoritmos de recomendação automatizados.

Esses sistemas de recomendação são ferramentas computacionais que visam prever a avaliação ou a preferência que um usuário atribuiria a um item. A abordagem mais utilizada é a Filtragem Colaborativa, que se baseia no princípio de que usuários que já concordaram no passado tenderão a concordar no futuro. Entretanto, esse modelo sofre do problema do começo frio (cold start) para novos usuários e novos itens, já que não possuem avaliações, e tende a criar um loop que reforça a popularidade de itens já conhecidos, marginalizando ainda mais a long tail.

Em contraste, a Filtragem Baseada em Conteúdo recomenda itens similares àqueles que o usuário gostou no passado, analisando as características dos próprios itens [3]. Para os livros, essas características podem incluir gênero, autor, palavras-chave e, no contexto deste trabalho, subgêneros literários e sinopses. A vantagem desse modelo é a capacidade de recomendar itens de nicho, assim, o sistema proposto neste trabalho se alinha à ideia desse modelo de recomendação.

Para operacionalizar essa filtragem baseada em conteúdo de forma relacional foram utilizados os grafos, estruturas matemáticas ideais para capturar conexões entre temas. Na modelagem proposta os nós representam os subgêneros e as arestas seriam a similaridade temática, transformando o catálogo de livro em uma rede semântica navegável. A aplicação de estrutura de grafos na modelagem de sistemas de recomendação para o domínio literário não é inédita, como no artigo apresentado por Chahinez Benkoussas e Patrice Bellot [4], onde os autores investigam a criação de um sistema de recomendação de livros que integra técnicas de Recuperação de Informação (RI) com Análise de Grafos.

Este trabalho se posiciona na mesma linhagem dessas pesquisas que utilizam grafos para recomendação de livro, mas que trabalham com uma nova abordagem de modelagem conceitual e uma estratégia algorítmica distinta. Além de incorporar Árvore de Huffman como uma camada de eficiência, já que adiciona uma preocupação com a otimização e a representação compacta dos interesses, algo que é crucial para a escalabilidade. Desenvolvido por David A. Huffman (1952) [5], esse algoritmo de compressão atribui códigos binários

para símbolos, onde os mais frequentes recebem os códigos mais curtos. Utilizando o conceito de codificação de Huffman para manejar um grande volume de dados e associações livro-subgênero de forma eficiente em termos de armazenamento e transmissão.

III. METODOLOGIA

A implementação do sistema de recomendação proposto foi estruturada em um pipeline modular de quatro etapas sequenciais, conforme ilustrado na Figura 1. Cada etapa foi desenvolvida como um módulo em Python independente, garantindo a reprodutibilidade e clareza no processo. A base de dados utilizada foi conjunto GoodReads_100k_books, disponível publicamente no Kaggle, que contém metadados de livros, incluindo título, autor, sinopse, gêneros, nota média e número de avaliações.




Fig. 1: Fluxo da Metodologia Proposta

A. Pré-processamento e normalização dos dados

A primeira etapa, implementada no módulo baseClean.py, focou na preparação e consolidação dos dados brutos. Foram aplicadas as seguintes operações:

1) *Filtragem e limpeza básica*: Os registros com campos essenciais ausentes, como título, sinopse, gênero, nota e número de avaliações foram removidos. As colunas de nota e número de avaliações foram convertidas para tipos numéricos.

2) *Unificação de edições*: Para evitar o caso de duplicatas, as edições de um mesmo livro foram agrupadas. Essa agregação foi feita por títulos e autor normalizados, somando o total de avaliações e calculando uma nova média ponderada para a obra consolidada.

3) *Processamento de texto*: As sinopses foram preparadas para análise semântica. O processo incluiu conversão de todas as letras para minúsculas com o intuito de manter um padrão de pesquisa, remoção de caracteres não-alfabéticos, tokenização e eliminação de *stopwords*, resultando em uma representação mais limpa do conteúdo, localizada na lista `cleaned_desc`.

4) *Normalização de gêneros*: A string de gêneros fornecida foi separada em uma lista de subgêneros individuais. Estes foram padronizados (ex.: mapeando “*sci-fi*” para “*science fiction*”) e limpos, gerando a lista `cleaned_genres`.

5) *Cálculo da relevância estatística (Weighted Rating)*: Para superar o viés de popularidade e dar confiabilidade às notas, adotou-se uma estimativa da Média Bayesiana [6] (aplicada em sistemas como o IMDb), uma técnica discutida como forma de suavizar avaliações e lidar com a escassez de dados em casos de *cold start* [4]. A Nota Ponderada (`weighted_rating`) para um livro é calculada como:

$$WR = \frac{v \cdot R + m \cdot C}{v + m}$$

Onde R é a nota média do livro, v o seu número de votos, C a nota média global de todo o dataset e m funciona como um limiar mínimo de votos para confiança estatística, definido na prática como 1000. Esta métrica equilibra a nota observada do livro com a média global.

O resultado desta etapa é uma base de dados consolidada (`goodreads_graph_base_clean.csv`), onde cada linha associa um livro a um de seus subgêneros, contendo os metadados limpos e sua nota ponderada.

B. Modelagem dos vértices: Árvores de Huffman híbridas

Cada subgênero literário foi modelado como um vértice no grafo semântico. A inovação proposta situa-se na estrutura interna de cada vértice, que encapsula duas árvores de Huffman construídas pelo módulo `vertice.py`:

1) *Árvore de Huffman de Popularidade*: Para um determinado subgênero, uma árvore é construída utilizando como entrada os livros pertencentes a ele. Cada livro, representado por seus metadados: autor e título, é um símbolo, e sua nota ponderada é a sua frequência. O algoritmo de Huffman agrupa iterativamente os itens de menor frequência, resultando em uma árvore binária onde os livros com maior relevância estatística, ou seja, que apresentam notas ponderadas maiores, posicionam-se estruturalmente mais próximos à raiz.

2) *Árvore de Huffman Semântica*: Uma segunda árvore é construída a partir do conteúdo textual das sinopses dos livros do subgênero. O corpo de todas as sinopses é unificado, e a frequência de cada palavra é contabilizada. As palavras mais frequentes no contexto daquele subgênero tornam-se símbolos de alta frequência e são posicionadas próximas à raiz da árvore.

Essa modelagem híbrida permite que cada vértice (subgênero) seja caracterizado por um perfil duplo: um perfil de relevância/popularidade interna e um perfil baseado no seu conteúdo temático.

C. Definição de arestas: Similaridade baseada em BFS e métricas estruturais

A conexão entre dois vértices é determinada por uma medida de similaridade híbrida, calculada no módulo `arestas.py`. A similaridade é baseada na proximidade das estruturas internas das árvores de Huffman.

Para quantificar a estrutura de uma árvore de Huffman foi utilizado o algoritmo de Busca por Largura (BFS). O BFS percorre a árvore nível a nível e calcula a profundidade média das folhas (d). Esta métrica reflete a dispersão da árvore, se essa árvore apresenta folhas (nesse caso seriam os livros ou as palavras) concentradas em níveis próximos a ela terá uma profundidade média menor, indicando alta homogeneidade, ou seja, todos os livros são muito relevantes ou as palavras são muito comuns. Uma árvore com folhas espalhadas por muitos níveis terá uma profundidade média maior, indicando maior diversidade interna.

A similaridade S entre dois subgêneros A e B é uma média harmônica da similaridade de suas estruturas de popularidade e semântica:

$$S(A, B) = \frac{S_{pop}(A, B) + S_{sem}(A, B)}{2}$$

Onde cada componente é definido como o inverso da diferença absoluta entre as profundidades médias:

$$S_x(A, B) = \frac{1}{1 + |\bar{d}_{Ax} - \bar{d}_{Bx}|}$$

Sendo x representando a árvore de popularidade (*pop*) ou a árvore semântica (*sem*). Esta função gera um valor entre 0 e 1, onde 1 indica identidade estrutural perfeita.

Uma aresta não direcionada e ponderada é criada entre os dois subgêneros se, e somente se, $S(A, B) \geq \theta$, onde θ é o limiar de similaridade. O peso da aresta é o valor da similaridade. Este processo resulta em um arquivo de arestas (`goodreads_graph_edges.csv`), que, em conjunto com os vértices modelados, forma o grafo semântico final.

D. Sistema de recomendação e interface

O módulo `interface_usuario.py` orquestra o pipeline e fornece a funcionalidade de recomendação. Dado um subgênero de interesse inicial fornecido pelo usuário, o sistema:

1. Recupera todos os seus vizinhos diretos no grafo, os subgêneros conectados por arestas.

2. Ordena esses vizinhos pelo peso da aresta, considerando similaridade decrescente.

3. Para o subgênero inicial e seus vizinhos, gera um ranking dos livros mais relevantes com base na média ponderada.

4. Apresenta ao usuário uma lista de livros, organizada por subgêneros semanticamente relacionados, promovendo assim uma descoberta temática guiada.

A ferramenta visualizador.py complementa o sistema, gerando relatórios detalhados que expõem a estrutura interna das árvores de Huffman e as conexões do grafo para inspeção e validação.

E. Construção dos grafos

Para criar a visualização dos grafos de gêneros foram exportadas as planilhas de arestas dadas pelo programa sendo elas "goodreads_graph_edges" e "usuario_subgrafo", essas planilhas já foram formatadas para serem aceitas pelo Gephi.

Ao exportar foi executado o comando Modularity Class, em Estatística, que executa um algoritmo de detecção de comunidades. Ela analisa a estrutura dos grafos, e cria grupos de nós com base na densidade das arestas, onde grupo com muitas conexões internas é considerado uma comunidade e com isso ela atribui IDs de cada classe. Para visualizar a coluna resultante, segui os passos=aparências; Nos; Cor; Partition e selecionei o atributo do comando anterior e selecionei as cores desejadas. Com isso obtivemos um resultado visual de subgrupos de gêneros similares do grafo originário e de uma filtragem.

Depois é executado o comando Average Weighted Degree (Grau Ponderado Medio), também encontrado em Estatística. Ele calcula a média da soma dos pesos das arestas conectadas a cada nó. Matematicamente ele encontra o grau (Degree) e depois faz o que é chamado de grau Ponderado (Weighted Degree): Soma os pesos dessas conexões. Para visualizar a partir da coluna resultante eu sigo os passos=aparências; Nos; Tamanho; Ranking e selecionamos no atributo o Grau Ponderado, coloco e configuro min=150; max=500. Ao aplicar, ele ajusta o tamanho dos nós. Nós com maior grau ponderado (muitas conexões fortes) ficam maiores, indicando que são gêneros "centrais" ou "hubs" que conectam muitas partes do grafo.

O próximo passo é selecionar a distribuição, primeiro a chamada "Force Atlas 2", sem alterar a configuração padrão. Este algoritmo de força dirigida simula um sistema físico de atração e repulsão, permitindo a visualização clara de clusters e a identificação de comunidades de gêneros, agrupando espacialmente os vértices que possuem maior densidade de conexões (similaridade)." Como resultado temos os grupos encontrados com o Modularity Class mas unidos e uma visualização mais clara de conexões entre eles.

Logo, em seguida aplicamos Fruchterman Reingold. Ele funciona com base em dois princípios inspirados na física de partículas onde os nós conectados se atraem e os nós desconectados se repelem, semelhante ao Force Atlas 2, mas a grande diferença é que o Fruchterman tenta distribuir os nós de forma mais uniforme e esférica, preenchendo melhor

o espaço disponível, ao invés de criar clusters tão densos e separados. Ele dá menos ênfase em Clusters não separando os grupos tão nitidamente quanto o Force Atlas 2. É melhor para ver as conexões das arestas. Mas para uma visualização igual as obtidas nos grafos desse artigo, foi executado inicialmente com a configuração padrão do algoritmo e depois executado novamente, mas com a configuração alterada em Área sendo colocado o valor 1.0E8, o que deixa a visualização mais clara e organizada.

E por último, na aba de Visualização, foi ativado nas configurações em Arestas o Reescalonar peso (Rescale weight) que serve para adaptar a espessura visual das arestas para uma escala visível na tela, mantendo a proporção entre elas. Ela pega o menor peso do grafo e o maior peso e mapeia esses valores para a Espessura (Thickness) usando eles como uma proporção. Ao marcar como ativa alteramos os valores do Min para 1 e do Max para 3, e logo depois a espessura em 10 e desmarcando as curvas. Assim, temos um grafo com arestas mais visíveis e com espessuras proporcionais a seus pesos.

IV. RESULTADOS E DISCUSSÃO

No grafo inicial, consideramos o foco apenas no gênero gótico que foi escolhido para iniciar a sequência de filtragem.




Fig. 2: Grafo obtido ao filtrarmos todo o dataset para retornar apenas as ligações com o gênero Gótico.

Na Figura 2, a sua visualização abrange todo o cluster do gênero "Gótico", que serve como ponto de partida. Neste estágio, o grafo demonstra a conectividade de todos os subgêneros ligados ao Gótico, representando todas as opções disponíveis para o leitor. A densidade das arestas dentro deste cluster mostra a alta similaridade entre os temas góticos.

A. Exemplo de Nós Modulares

Classe 0 (Realidade e História): Agrupou gêneros de não-ficção, históricos e sociológicos (ex: War, Religion, True

Vertice/Gênero	Modularity Class/No	Grau ponderado
war	0	71,53
classic literature	1	24,45
horror	2	23,18

Fig. 3: Relação entre nós modulares e seus graus ponderados.

Crime), mostrando que obras baseadas em fatos compartilham uma topologia de popularidade distinta da ficção.

Classe 1 (Literatura e Cultura): Reuniu a ficção literária, clássicos e obras categorizadas por geografia ou arte (ex: Classic Literature, Magical Realism), representando o cânone literário e narrativas culturais.

Classe 2 (Gótico e Especulativo): Isolou o núcleo temático do estudo, conectando o Gótico a gêneros de horror, sobrenatural e fantasia urbana (ex: Gothic, Vampires, Victorian). A forte conexão mostrada em Grau Ponderado entre 'Victorian' e 'Vampires' neste cluster corrobora a afinidade histórica e temática entre esses nichos. Isso demonstra que o algoritmo conseguiu separar com sucesso "História Real", "História Literária" e "Ficção Gótica", apenas analisando a matemática das árvores.

A análise de centralidade baseada no Grau Ponderado evidenciou uma hierarquia clara na rede. Gêneros de não-ficção e thrillers, como 'True Crime' e 'Religion', apresentaram os maiores índices (>70) na tabela e podem ser vistos como maiores vértices, indicando que possuem uma topologia de popularidade genérica, compartilhada por muitos outros subgêneros.

Em contraste, gêneros centrais ao tema gótico, como 'Victorian' (20.8) e 'Urban Fantasy' (26.4), situaram-se na extremidade inferior da escala. Este isolamento relativo é um indicador positivo de especificidade: sugere que a estrutura das suas árvores de Huffman (tanto em termos de vocabulário quanto de distribuição de ratings) é única e distinta, conectando-se apenas a pares muito próximos, ao contrário de gêneros mais generalistas que funcionam como hubs universais.

Partindo para a visualização do grafo filtrado, foi introduzido o filtro para o subgênero "Historical Romance", o sistema aplica então o BFS a partir deste nó. O grafo resultante isola o subgênero escolhido, mas também exibe seus vizinhos diretos, ordenados pela similaridade, ou seja, o peso das arestas.

Essa filtragem da Figura 4 apresenta visualmente a identificação do caminho de maior similaridade a partir do ponto de interesse do usuário, que é o primeiro passo do algoritmo de recomendação. Revelando assim, os subgêneros que compartilham a maior afinidade semântica.

Ao analisar o subgrafo resultante do subgenero "Historical Romance", observou-se uma reação do tipo 'Hub-and-Spoke' (cubo e raios). O gênero central apresentou um Grau Ponderado significativamente elevado (26.93), enquanto a vasta




Fig. 4: Grafo obtido ao filtrarmos o cluster do gênero gótico em busca do subgênero Historical Romance.

Vertice/Gênero	Modularity y Class/No	Grau ponderado
historical romance	0,00	26,93
school	0,00	0,91
academic	0,00	0,91
writing	0,00	0,86

Fig. 5: Relação entre os vértices e seus respectivos subgêneros e os seus valores de graus ponderados.

maioria dos gêneros adjacentes (ex: 'Noir', 'Academic') exibiu valores inferiores a 1.0, indicando conexões singulares e dependentes do nó central.

Neste recorte específico, a rede é tão coesa e centralizada que o algoritmo não conseguiu (ou não precisou) dividi-la. Todos os gêneros listados formam uma única família temática unida pela sua conexão com a História e o Romance.

No final, foram utilizados dois subgêneros, "Classic Literature" e "Ghost Stories", o filtro age como uma confirmação visual para a descoberta. A métrica da profundidade média reflete a posição e a frequência dos dados nas árvores de Huffman associadas a cada subgênero

A profundidade média de popularidade para *Classic Literature*, com um valor aproximado de 2,8571, sugere que as obras deste subgênero possuem maior frequência no *dataset*. Já nas métricas de vocabulário, os valores de 6,75 e 6,82 para *Classic Literature* e *Ghost Stories*, respectivamente, demonstram que

TABLE I: Resultados Agrupados por Sub-Subgênero

Sub-Subgênero	Total de Obras	Profundidade Média (Popularidade)	Profundidade Média (Vocabulário)
Classic Literature	7	2.8571	6.7500
Ghost Stories	9	3.2222	6.8200

a complexidade textual das sinopses entre os dois subgêneros é similar, o que é um pré-requisito para que a função de similaridade encontre valores altos.

O cálculo quantitativo de similaridade entre o subgênero de entrada e os sub-subgêneros testados confirma as conexões visuais do grafo.

TABLE II: Similaridade e Posição dos Sub-Subgêneros em relação ao Subgênero Historical Romance

Sub-Subgênero	Similaridade com Historical Romance	Posição no Ranking
Classic Literature	84.1%	5 ^a
Ghost Stories	75.6%	11 ^a

A conexão de 84.1 é o achado mais significativo. Isso demonstra que a combinação das métricas de Huffman (Popularidade e Vocabulário) priorizou a afinidade temática do *Historical Romance* com o *Classic Literature* acima de diversas outras categorias.

O sistema então identificou uma conexão mais forte entre *Classic Literature* e *Historical Romance*, indicando que ao combinarmos popularidade e conteúdo, foi encontrado maior afinidade entre estes dois subgêneros. Demonstrando a capacidade do sistema de ir além da popularidade bruta e encontrar ligações conceituais.

Os resultados demonstram que o sistema de recomendação, quando utiliza essa abordagem centrada em grafos e na estrutura de dados interna dos itens consegue mapear, identificar e priorizar conexões temáticas relevantes. A evolução das visualizações do grafo, juntamente com a precisão das métricas quantitativas, indica que o sistema consegue ser uma alternativa eficaz aos algoritmos baseados predominantemente em popularidade, o que facilita a exploração mais inteligente do mundo literário com base na afinidade semântica.

V. CONCLUSÃO E TRABALHOS FUTUROS

Esse trabalho propôs, implementou e avaliou um sistema de recomendação literária inovador, cujo objetivo central foi deslocar o foco da recomendação baseada em popularidade (best-sellers) para uma curadoria centrada na compatibilidade temática profunda entre livros e subgêneros. Diante do cenário de information overload e da predominância de algoritmos que reforçam um ciclo de popularidade, a solução desenvolvida apresenta uma alternativa baseada em conteúdo e estrutura de dados.

A principal contribuição deste artigo é a combinação de três estruturas fundamentais: grafos, árvores de Huffman e o algoritmo de Busca em Largura (BFS). Ao modelar cada subgênero como um vértice que contém duas árvores de

Huffman híbridas, uma para a popularidade, baseada na Média Bayesiana, e outra para o conteúdo semântico, extraído das sinopses. Dessa forma foi possível criar um perfil duplo de cada nicho literário.

A conexão entre esses vértices usando uma medida de similaridade híbrida, calculada a partir de métricas estruturais, no caso a profundidade média das folhas, extraídas via BFS, resultou na geração de um grafo semântico agradável. Este grafo demonstrou capacidade de formar clusters intuitivos, conectar subgêneros por afinidade intrínseca e, principalmente, promover a descoberta de obras da long tail que compartilham propriedades fundamentais com os interesses do leitor, mas não necessariamente com sua popularidade.

Os resultados validam a hipótese inicial de que um sistema focado na análise estrutural do conteúdo e no relacionamento conceitual entre os subgêneros pode oferecer recomendações mais personalizadas e tematicamente relevantes.

A. Trabalhos futuros

Apesar dos resultados promissores, o trabalho apresenta limitações que abrem caminho para pesquisas futuras. Primeiramente, o sistema ainda depende criticamente da qualidade e consistência dos metadados fornecidos pela comunidade. A normalização de subgêneros dependeu de tags fornecidas pelos usuários do GoodReads, que podem ser inconsistentes. Além da existência de várias versões de um mesmo livro, com sinopses diferentes e que poderiam ter sido catalogados de maneira errônea já que esse tipo de informação depende do próprio usuário. Uma abordagem futura poderia utilizar outros processos para extrair temas e subtemas diretamente do texto completo das sinopses ou de resenhas, reduzindo essa dependência e criando uma representação de conteúdo mais rica e independente.

Em segundo lugar, a experiência do usuário pode ser personalizada dinamicamente. O perfil atual é um ponto de partida estático, depende dos seus subgêneros de interesse. Uma evolução seria modelar o histórico de leitura do usuário também como uma árvore de Huffman, permitindo calcular a similaridade diretamente entre o perfil do leitor e os vértices do grafo, ajustando ainda mais as recomendações.

Terceiro, a validação prática com utilizadores reais é um passo essencial. Embora a análise qualitativa dos clusters e das recomendações seja robusta, é necessário conduzir um estudo de usuários controlados para mensurar o impacto em métricas subjetivas como satisfação e novidade, que são críticas para a adoção de um sistema de recomendação. Finalmente, a otimização dos parâmetros [8], como o limiar de similaridade θ e o peso relativo entre as componentes de popularidade e semântica, pode ser explorada através de técnicas de otimização ou machine learning para maximizar a qualidade de recomendações para diferentes perfis de usuários.

Em resumo, este trabalho demonstra a viabilidade e o potencial de uma abordagem centrada em grafos e na estrutura de dados interna dos itens para o complexo problema da curadoria literária na era digital. Ao priorizar a afinidade semântica sobre o volume de vendas, o sistema proposto se apresenta como

um contraponto necessário para os algoritmos dominantes, oferecendo uma ferramenta para que leitores possam explorar de forma inteligente a vastidão do mundo literário.

VI. ALGORITMO E BASE DE DADOS

O código-fonte implementando o algoritmo apresentado neste artigo, na linguagem Python, e o dataset utilizado durante o artigo como base de dados inicial estão disponíveis, respectivamente, nos seguintes links:

<https://github.com/Lulu-blue/Artigo-Aeds-2.git>

<https://www.kaggle.com/datasets/mdhamani/goodreads-books-100k>

REFERENCES

- [1] ARMSTRONG, Robert. The long tail: Why the future of business is selling less of more. Canadian journal of communication, v. 33, n. 1, p. 127–128, 2008.
- [2] BAWDEN, David; ROBINSON, Lyn. Information Overload: An Introduction Oxford University Press, , 30 jun. 2020. (Nota técnica).
- [3] Ricci, Francesco; Rokach, Lior; Shapira, Bracha. (2010). Recommender Systems Handbook. 10.1007/978-0-387-85820-3-1.
- [4] BENKOUSSAS, Chahinez; BELLOT, Patrice. Information retrieval and graph analysis approaches for book recommendation. TheScientific-WorldJournal, v. 2015, n. 1, p. 926418, 2015.
- [5] CORMEN, T. H. et al. Introduction to Algorithms. 3rd ed. MIT Press, 2009.
- [6] MOORE, Andrew W.; ZUEV, Denis. Internet traffic classification using bayesian analysis techniques. In: New York, NY, USA: ACM, 2005.
- [7] D. A. Huffman, "A Method for the Construction of Minimum-Redundancy Codes," in Proceedings of the IRE, vol. 40, no. 9, pp. 1098-1101, Sept. 1952.
- [8] MONICA; AGRAWAL, Parul. A survey on hyperparameter optimization of machine learning models. In: IEEE, 2024.